

LLM vs. traditionelle Web-UI- Testfallgenerierung — Methodenentwurf

Zwei mögliche Studiendesigns zur Diskussion

Anschluss an die SLR-Befunde

Was wir wissen — und welche Lücke wir empirisch schließen wollen

Was die SLR ergeben hat

Traditionelle Verfahren (SBST, Crawljax, RL) sind stark bei Coverage und Determinismus.

LLM-Verfahren sind stark bei Verständlichkeit, Anforderungsnähe und Generierungsgeschwindigkeit.

Hybride Ansätze (S8, Cypress Copilot) deuten auf den größten Mehrwert hin — sind aber nur einzeln validiert.

Empirische Fragestellung

„Liefert ein LLM-gestütztes Verfahren auf gleichen User-Stories und Ziel-Anwendungen messbar bessere oder schlechtere Web-UI-Testskripte als ein autonomer Crawler — und schafft eine Hybrid-Pipeline einen zusätzlichen Mehrwert?“


Drei Pipelines, gemeinsame Metrik-Suite, drei Ziel-Anwendungen.

Methode 1 — Direkter Vergleich

Autonomer Crawler vs. LLM-Agent, einheitliche Bewertung

Methode 1 — Direkter Vergleich

Crawler und LLM-Agent erzeugen unabhängig Testskripte; DeepEval bewertet einheitlich.



Wie es funktioniert

Crawler-Strang

Playwright-Bot durchläuft die App selbständig, baut Zustandsgraphen, serialisiert Pfade als Testskript.

LLM-Strang


LLM-Agent bekommt User-Story und Browser-Zugriff, erkundet die App, produziert Testskript.

Bewertung

Skript_C und Skript_L durch denselben Test-Runner und DeepEval-Judge — objektive plus semantische Metriken.

Methode 2 — Hybrid: LLM verbessert traditionelles Skript

Erweitert Methode 1 um eine dritte Pipeline



Was zusätzlich passiert

Skript_C wird an einen LLM-Refiner weitergereicht.

Der Refiner bekommt einen klaren Auftrag:

- fragile CSS-Selektoren durch robuste Locator-Strategien ersetzen
- fehlende Assertions zur User-Story ergänzen
- Lesbarkeit und Wartbarkeit verbessern

Ergebnis: Skript_H

Drei-Wege-Vergleich gegen Skript_C und Skript_L.

Methode 1 vs. Methode 2 — Trade-offs

Was die Entscheidung praktisch beeinflusst

Kriterium	Methode 1 — Direkter Vergleich	Methode 2 — Hybrid
Pipelines	2 (Crawler, LLM)	3 (Crawler, LLM, Hybrid)
Implementierungs-Aufwand	moderat	moderat + 1 LLM-Aufruf
SLR-Lücken-Bezug	schwach	direkt (Hybrid-Designspace)
Wissenschaftliche Originalität	ähnelt Coppola 2024 (S1)	neuartige Drei-Wege-Studie
Erzähl-Komplexität	binär: A schlägt B	differenziert: Stärken pro Pipeline
Fallback bei Zeitnot	—	auf Methode 1 reduzierbar

Empfehlung: Methode 2 — aber inkrementell. Zuerst Methode 1 vollständig lauffähig, Hybrid-Stufe als zweiter Schritt dazuschalten.

Inkrementelles Vorgehen — Methode 1 als Fundament, Methode 2 als Aufsatz

Phase 1

Methode 1 (Wochen 1–4)

Crawler bauen, LLM-Agent integrieren, Test-Runner aufsetzen, DeepEval einbinden. Ergebnis: vollständige Studie als sicherer Hafen.

Phase 2

Methode 2 (Wochen 5–6)

Hybrid-Refiner als zusätzliches Modul. Skript_C als Eingabe, klar getrennter Prompt mit drei Verbesserungsachsen. Drei-Wege-Vergleich.

Phase 3

Auswertung (Wochen 7–8)

Visualisierung pro Metrik, narrative Diskussion entlang ISO 25010, Threats-to-Validity (LLM-Judge-Bias, Skript-Korpus-Größe).