

Ergebnisbericht — LLM vs. traditionelle Web-UI-Testfallgenerierung

Experiment **20260608-113457_juiceshop_9618a5** · OWASP Juice Shop · Provider **ollama** · Generierungs-Modell **minimax-m3** · Judge **gpt-oss:120b** · 2026-06-08 11:34 · 1 Wiederholung

Überblick — Metrik × Pipeline

Pipeline	ISO Funct. Suitability	SSR (Pass-Rate)	Ausführbar	Alle Tests grün	Gen-Zeit (s)
Skript_C — Crawler	0.350	0.000	ja	nein	439.7
Skript_L — LLM-Agent	0.361	0.167	ja	nein	501.2
Skript_H — Hybrid	0.122	0.333	ja	nein	265.4

Höher ist besser außer Gen-Zeit. ISO-Werte für Skript_C/L sind intrinsisch bewertet, für Skript_H story-bewusst (gegen die User-Stories) — daher nur eingeschränkt direkt vergleichbar.

Kernbefunde

- Erstmals laufen Tests durch:** Skript_L erreicht SSR 0.167, Skript_H 0.333 (zuvor 0/0). Skript_C bleibt bei 0 — der Crawler scheitert an SPA-spezifischen Aktionierbarkeits-Problemen.
- Scheinbarer Widerspruch H:** höchste Pass-Rate (0.333), aber niedrigste ISO (0.122). Grund: der story-bewusste Judge zieht Skript_H runter, weil es US-2/US-3/US-4 nicht abdeckt und Story-fremde Schritte (Contact, Sidenav) enthält (hohe Hallucination).
- Knappes Rennen Methode 1:** Skript_L (0.361) minimal vor Skript_C (0.350) — der LLM-Agent produziert eine breitere, lesbarere Suite, halluziniert aber Elemente.

Hauptfehlerursachen (aus den Test-Logs)

- Sidenav-Vorbedingung:** Klick auf „Go to contact us page“ läuft in den 15s-Timeout, weil der Link nur bei geöffneter Sidenav klickbar ist (Crawler + Hybrid). Echter SPA-Effekt.
- Overlay fängt Klicks ab:** der CDK-Overlay-Backdrop bzw. das wiederkehrende Cookie-Banner („Me want it!“) blockiert Aktionen — der Dismiss-Handler feuert wiederholt.
- LLM-Halluzination (Skript_L):** der Agent referenziert Juice-Shop-fremde Elemente (z. B. „Field with the name of the author“, „Button to send the review“) — vom Judge korrekt als hoch markiert.

DeepEval-Judge — verdichtete Begründungen

Pipeline	Bewertung (Kurzfassung)
Skript_C	Aktionen kohärent, Assertions aber generisch (about:blank, body); brüchiger CSS-Selektor „#searchQuery > div > input“; keine Halluzination; generische Testnamen.
Skript_L	Realistische, web-first formulierte Flows und Assertions; jedoch klar erfundene UI-Elemente (hohe Hallucination); intrinsisch solide, aber ungeerdet.
Skript_H	Deckt nur US-1 teilweise ab, US-2/3/4 fehlen; fügt Story-fremde Schritte hinzu; brüchiger CSS-Selektor; gut strukturiert, aber geringe Anforderungs-Abdeckung.

Einordnung & Threats to Validity

- Nur **1 Wiederholung** und **eine Ziel-App** — keine Standardabweichung, statistisch noch nicht belastbar.
- Crawler-Blindspot:** Angular-(click)-Elemente ohne href sind für den DOM-Crawler unsichtbar; Sidenav-Inhalte nur eingeschränkt erreichbar — strukturelle Grenze, kein Tool-Fehler.
- Entkoppelte Bewertung:** C/L intrinsisch, H story-bewusst → Judge-/ISO-Zahlen zwischen Methode 1 und 2 nur eingeschränkt direkt vergleichbar (objektive Metriken wie SSR voll vergleichbar).
- LLM-Judge-Bias:** Generator (minimax-m3) und Judge (gpt-oss:120b) bewusst aus verschiedenen Familien.