

Ergebnisbericht — LLM vs. traditionelle Web-UI-Testfallgenerierung

Experiment 20260615-083622_juiceshop_09b201 · OWASP Juice Shop · Generierung minimax-m3 · Judge gpt-oss:120b · 5 Wiederholungen · Coverage-Nenner 26 · Stories US-1...US-4 · 2026-06-15

Vergleichstabelle — Metrik × Pipeline (Mittelwert ± Std über 5 Läufe)

Metrik	Skript_C Crawler	Skript_L LLM o. Story	Skript_S LLM + Story	Skript_H Hybrid
Gen-Zeit (s) (-)	675.1	499.6 ±65.2	518.7 ±76.0	97.3 ±41.3
# Tests	3	5.8 ±2.6	2.2 ±1.5	2.6 ±1.9
SSR / Pass-Rate (+)	0.333	0.487 ±0.18	0.150 ±0.20	0.247 ±0.21
Laufzeit (s) (-)	44.2 ±0.9	41.1 ±26.3	23.2 ±13.6	28.8 ±25.8
Judge Correctness (+)	0.98 ±0.04	0.88 ±0.24	0.42 ±0.24	0.20
Judge Appropriateness (+)	0.60 ±0.14	0.72 ±0.28	0.46 ±0.24	0.34 ±0.05
Judge Hallucination (-)	n/a	0.78 ±0.29	0.74 ±0.27	0.78 ±0.29
Judge Readability (+)	0.72 ±0.16	0.84 ±0.10	0.58 ±0.31	0.58 ±0.23
ISO Correctness (+)	0.657 ±0.02	0.683 ±0.15	0.285 ±0.21	0.223 ±0.10
ISO Completeness (+)	0.0 *	0.0 *	0.0 *	0.0 *
ISO Appropriateness (+)	0.60 ±0.14	0.72 ±0.28	0.46 ±0.24	0.34 ±0.05
ISO Functional Suitability (+)	0.419 ±0.05	0.468 ±0.13	0.248 ±0.12	0.188 ±0.05

(+) höher = besser, (-) niedriger = besser. n/a = nicht anwendbar (Crawler kann nicht halluzinieren). * ISO Completeness war durch einen Mess-Bug bei der genutzten Coverage auf 0 (inzwischen behoben) → die ISO-Gesamtwerte sind hier untertrieben; ein neuer Lauf liefert korrekte Completeness.

Kernbefunde

- **LLM-only (Skript_L) am stärksten in der Ausführung:** beste SSR (0.49) und ISO (0.47) — breite, lauffähige Suite — aber hohe Halluzination (0.78).
- **Story macht den Agenten nicht automatisch besser:** Skript_S (LLM + Story) hat die **schlechteste** SSR (0.15). Die Story treibt ihn zu spezifischeren, aber **erfundenen** Locatorm (z. B. `get_by_placeholder("Apple")`, Rolle „Email address field“) → Grounding-Fehler.
- **Crawler:** sehr hohe intrinsische Correctness (0.98), aber nur SSR 0.33 — scheitert am Sidenav-Link (Element nur bei offener Sidenav klickbar). Halluzination konstruktionsbedingt n/a.
- **Hybrid (Skript_H):** niedrigste ISO (0.19); veredelt zwar Skript_C, fügt aber ungeerdete Sidenav-Schritte hinzu (Halluzination 0.78).

Stabilität / Varianz (N = 5)

- **LLM-Pipelines sind instabil:** Skript_S Testanzahl 1–4, SSR 0.15 ±0.20; Skript_H Testanzahl 0–5, SSR 0.25 ±0.21. Hohe Varianz in fast allen Kennzahlen.
- **Crawler ist stabil** (deterministisch): Laufzeit 44.2 ±0.9, Correctness 0.98 ±0.04.
- Bestätigt den Nichtdeterminismus-Threat: Einzelläufe von LLM-Verfahren sind nicht repräsentativ — Mittelwert ± Std ist nötig.

Einordnung & Threats to Validity

- **N = 5, eine Ziel-App** (Juice Shop) — Tendenzen, noch keine Verallgemeinerung.
- **Crawler-Blindspot:** Angular-(click)-Elemente ohne href (Produktkacheln) sind für den DOM-Crawler unsichtbar — strukturelle Grenze, kein Fehler.
- **Mess-Bug (beheben):** genutzte Coverage zählte bestandene Tests nicht (pytest-`[chromium]`-Suffix) → ISO Completeness 0. Nach Fix liefert ein neuer Lauf belastbare Completeness/ISO.
- **Entkoppelte Bewertung:** C/L intrinsisch, S/H story-bewusst → semantische Scores zwischen Methode 1 und 2 nur eingeschränkt direkt vergleichbar; objektive Metriken (SSR) voll vergleichbar.
- **Judge-Familie:** Generator (minimax) und Judge (gpt-oss) bewusst verschieden → geringer Bias.