

Planning der systematischen Literaturübersicht

Vergleich von LLM-basierten und traditionellen Ansätzen zur automatisierten Testfallgenerierung in Web-UI- und End-to-End-Tests von Webanwendungen

1 Zielsetzung der Arbeit

Die automatisierte Testfallgenerierung zählt zu den aktivsten Forschungsfeldern des Software-Engineerings, da sie unmittelbar auf Zuverlässigkeit, funktionale Korrektheit und Wartbarkeit einwirkt. Innerhalb webbasierter Software stellen die Benutzungsoberfläche und ihre End-to-End-Tests einen besonders anspruchsvollen Gegenstand dar: Sie sind ereignisgesteuert, zustandsbehaftet, hochgradig dynamisch (etwa durch asynchrone Kommunikation, Single-Page-Architekturen und DOM-Mutationen) und damit deutlich schwerer zu modellieren als reine Funktionsschnittstellen. Gleichzeitig haben kurze Release-Zyklen und Continuous-Deployment-Pipelines den Bedarf an robuster, automatisierter UI-Testautomatisierung erheblich erhöht.

Traditionelle Verfahren wie suchbasierte Testgenerierung, modellinferenzgestützte Crawler (z. B. Crawljax) oder skript- und mutationsbasierte Ansätze sind in der UI-Forschung etabliert. Ihre Wirksamkeit hängt jedoch stark von präzise vorgegebenen Modellen und stabilen Selektoren ab, was die Übertragbarkeit auf moderne, häufig veränderte Frontends einschränkt. Jüngere Ansätze auf Basis großer Sprachmodelle (LLMs) bzw. LLM-gestützter Code-Agenten versprechen hier Fortschritte, da sie implizites Wissen über Web-Frameworks, gängige Interaktionsmuster und natürlichsprachliche Anforderungen nutzen, um Testszenarien und ausführbare Skripte direkt zu erzeugen.

Trotz wachsender Einzelstudien fehlt eine methodisch kontrollierte Übersicht, die LLM-basierte und traditionelle Verfahren speziell im Web-UI- und End-to-End-Kontext vergleichend betrachtet. Bestehende Übersichtsarbeiten konzentrieren sich entweder auf Unit-Tests oder behandeln REST-/Web-API-Tests, in denen die Studienlage bereits stark konsolidiert ist. Die vorliegende Arbeit adressiert die Web-UI-Lücke durch eine systematische Literaturübersicht nach Kitchenham und Charters mit PRISMA-konformer Dokumentation. Als analytischer Rahmen dient ISO/IEC 25010, insbesondere die Functional Suitability (Functional Correctness, Completeness, Appropriateness); das Modell wird nicht als Bewertungsmaßstab der Primärstudien unterstellt, sondern als einheitliches Begriffsgerüst zur Einordnung und Synthese ihrer Ergebnisse genutzt.

Zwei Abgrenzungen sind für den Zuschnitt der Arbeit zentral. Erstens werden ausschließlich Verfahren betrachtet, die Testfälle für die Benutzungsoberfläche webbasierter Anwendungen erzeugen, einschließlich End-to-End-Tests, die typischerweise über Browser-Automatisierung mit Werkzeugen wie Selenium, Playwright oder Cypress ausgeführt werden. Verfahren, die ausschließlich auf der REST- bzw. Web-API-Ebene operieren und keinen UI-Bezug aufweisen, werden nicht untersucht; sie bilden ein eigenständiges, bereits gut konsolidiertes Forschungsfeld und werden lediglich abgrenzend erwähnt (vgl. EC1). Zweitens betrifft die Arbeit die Testfallgenerierung im Sinne vollständiger Testfälle einschließlich Logik, Ablauf und Orakel; Testdatengenerierung als eigenständiges Forschungsfeld wird nur insoweit gestreift, wie sie als Hilfsmittel innerhalb der untersuchten Verfahren auftaucht (vgl. EC7).

2 Forschungsfragen

Die zentrale Forschungsfrage lautet: Wie unterscheiden sich LLM-basierte und traditionelle Ansätze zur Testfallgenerierung in webbasierten Benutzungsoberflächen hinsichtlich der Testqualität gemäß ISO/IEC 25010? Zu ihrer systematischen Beantwortung wird sie in drei aufeinander aufbauende Unterfragen überführt. RQ1 betrachtet den Stand der Technik und fragt, welche Ansätze zur Testfallgenerierung für Web-UI- und End-to-End-Tests in der Literatur beschrieben werden. RQ2 untersucht, welche Qualitätskriterien und Metriken zur Bewertung generierter Testfälle verwendet werden und inwiefern sich diese auf ISO/IEC 25010 abbilden lassen. RQ3 prüft abschließend, welche Evidenz für Unterschiede zwischen beiden Ansatzfamilien hinsichtlich Korrektheit, Vollständigkeit, Angemessenheit sowie weiterer testbezogener Metriken wie Coverage, Fehlererkennung, Ausführbarkeit, Flakiness oder Verständlichkeit besteht.

3 Suchstrategie

Die Suchstrategie folgt einem konzeptbasierten Vorgehen: Die Forschungsfragen werden in thematische Konzeptgruppen zerlegt, deren Terme innerhalb einer Gruppe per OR und zwischen den Gruppen per AND kombiniert werden. Die Konzepte sind dabei bewusst orthogonal angelegt: C1 fixiert den Untersuchungsgegenstand „Testfallgenerierung als Aktivität“ und legt fest, was generiert wird, während C2 und C3 die Methodendimension abbilden und festlegen, wie generiert wird. C2 (LLM) und C3 (traditionell) werden per OR verbunden, um sowohl LLM- als auch traditionelle und vergleichende Arbeiten einzuschließen. C4 grenzt bewusst eng auf die Web-UI- und E2E-Ebene ein und schließt reine REST-/API-Studien aus, weil diese ein eigenständiges, bereits gut konsolidiertes Forschungsfeld bilden. C5 öffnet das Suchfeld zusätzlich für qualitäts- und metrikorientierte Arbeiten. Gesucht wird jeweils in Titel, Abstract und Schlagwörtern.

Konzeptgruppe	Beschreibung	Beispielhafte Suchbegriffe
C1 Untersuchungsgegenstand	Aktivität der Testfallgenerierung als solche, unabhängig vom konkreten Verfahren. Dient der thematischen Eingrenzung auf Arbeiten, die Testfälle bzw. Testskripte erzeugen.	"test case generation", "test generation", "test suite generation", "test script generation"
C2 Methode – LLM	Methodische Dimension: Verfahren auf Basis großer Sprachmodelle oder LLM-Agenten.	"large language model", "LLM", "GPT", "ChatGPT", "code agent", "prompt engineering"
C3 Methode – Traditionell	Methodische Dimension: etablierte, nicht-LLM-basierte algorithmische Verfahren.	"symbolic execution", "search-based", "SBST", "model-based testing", "fuzzing", "concolic"
C4 Web-UI / E2E	Eingrenzung auf die Benutzungsoberfläche webbasierter Anwendungen sowie End-to-End-Tests durch Browser-Automatisierung.	"web application", "web app", "web-based", "web UI", "GUI testing", "end-to-end testing", "E2E", "browser automation", "Selenium", "Playwright", "Cypress", "DOM", "single page application", "SPA", "web form"

Konzeptgruppe	Beschreibung	Beispielhafte Suchbegriffe
C5 Qualität / Metriken	Bewertungsdimensionen gemäß ISO/IEC 25010 und gängigen Testmetriken.	"test quality", "functional suitability", "coverage", "fault detection", "mutation score", "flakiness"

Die daraus resultierende Unified Boolean Query lautet: (C1) AND ((C2) OR (C3)) AND (C4) AND (C5). Ausformuliert ergibt sich beispielsweise: ("test case generation" OR "test generation" OR "test suite generation" OR "test script generation") AND (("large language model" OR "LLM" OR "GPT" OR "ChatGPT" OR "code agent" OR "prompt engineering" OR "foundation model") OR ("search-based" OR "SBST" OR "model-based testing" OR "crawljax" OR "DOM crawl" OR "random testing" OR "capture-replay")) AND ("web application" OR "web UI" OR "GUI testing" OR "end-to-end testing" OR "E2E" OR "browser automation" OR "Selenium" OR "Playwright" OR "Cypress" OR "single page application" OR "web form") AND ("test quality" OR "coverage" OR "fault detection" OR "mutation score" OR "functional suitability" OR "flakiness" OR "executability"). Als Datenbanken werden IEEE Xplore, ACM Digital Library, Scopus und SpringerLink verwendet, ergänzt um eine eingeschränkte arXiv-Recherche, da bedeutsame LLM-Arbeiten häufig zunächst als Preprint erscheinen. Limitationen bleiben bestehen, insbesondere terminologische Heterogenität im KI-Umfeld, rasche Veralterung von Modellnamen, eine Sprachverzerrung durch die Einschränkung auf englisch- und deutschsprachige Arbeiten sowie das Risiko, dass UI-Studien ohne explizite Web-Terminologie übersehen werden. Diesen Risiken wird durch Snowballing und die Validierung per Quasi-Gold-Standard begegnet.

4 Search Execution Plan

Die Suche wird in reproduzierbaren Schritten durchgeführt. Zunächst wird die Unified Boolean Query datenbankspezifisch angepasst und parallel in allen Datenbanken ausgeführt; Datum, Filter und Trefferzahlen werden protokolliert. Die Treffer werden in eine zentrale Referenzdatenbank überführt, in der Duplikate zunächst automatisiert über DOI und Titel und anschließend manuell auf Basis inhaltlich nahezu identischer Einträge entfernt werden.

Die Studienauswahl erfolgt dreistufig: Titel-Screening, Abstract-Screening und Volltextanalyse. Unklare Fälle werden jeweils in die nächste Stufe übernommen, um vorzeitige Reduktion zu vermeiden. Anschließend wird Snowballing durchgeführt. Im Backward-Snowballing werden die Referenzlisten eingeschlossener Studien systematisch geprüft; im Forward-Snowballing werden über Zitations-Tracking jene Arbeiten identifiziert, die die eingeschlossenen Studien zitieren. Das Snowballing wird iterativ wiederholt, bis in zwei aufeinanderfolgenden Iterationen keine zusätzliche einschlussrelevante Arbeit mehr identifiziert wird (Sättigung als Stopping Rule).

5 Search Validation

Zur Validierung der Suchstrategie wird ein Quasi-Gold-Standard (QGS) eingesetzt. Vor der eigentlichen Datenbankrecherche wird dazu eine kleine, sorgfältig kuratierte Menge von Primärstudien zusammengestellt, die aufgrund ihrer thematischen Nähe mit hoher Sicherheit als relevant gelten. Die finalisierte Unified Boolean Query wird gegen diesen QGS geprüft; gemessen wird der Recall, also der Anteil der QGS-Studien, die durch die Datenbankabfrage gefunden werden. Liegt der Recall unter 80

%, werden Suchterme erweitert und die Gruppenstruktur angepasst. Der Vorgang wird iterativ bis zum Erreichen des Schwellenwerts wiederholt und versioniert dokumentiert.

6 Inclusion- und Exclusion-Kriterien

Die Kriterien werden vor Beginn des Screenings verbindlich festgelegt, operationalisieren die Forschungsfragen und bleiben über alle Stufen hinweg konsistent. Zur Reduktion individueller Verzerrung wird eine Teilmenge der Treffer doppelt bewertet und die Übereinstimmung per Cohens Kappa quantifiziert; bei Abweichungen werden die Kriterien präzisiert.

Einschlusskriterien (IC)	Ausschlusskriterien (EC)
IC1 Automatisierte Testfallgenerierung für die Benutzungsoberfläche webbasierter Anwendungen oder für End-to-End-Tests, die durch Browser-Automatisierung ausgeführt werden.	EC1 Studien, deren Gegenstand ausschließlich Web-/REST-APIs ohne UI-Bezug ist, sowie Studien zu Nicht-Webumgebungen (z. B. eingebettete Systeme, Desktop, native Mobile).
IC2 LLM-basierter oder traditioneller Ansatz bzw. expliziter Vergleich.	EC2 Weder klar LLM-basiert noch einem etablierten Verfahren zuzuordnen.
IC3 Empirische Auswertung generierter Testfälle (Korrektheit, Coverage, Fehlererkennung).	EC3 Rein konzeptionelle oder vision-artige Beiträge ohne Empirie.
IC4 Peer-Review-Publikation; hochwertige Preprints werden separat geprüft.	EC4 Kurzbeiträge (< 4 Seiten), Poster, Tutorials, Keynotes.
IC5 Englisch- oder deutschsprachige Veröffentlichung ab 2015.	EC5 Duplikate, andere Sprachen ohne Übersetzung, Sekundärliteratur als Primärquelle.
IC6 Gegenstand sind generierte Testfälle (Logik, Struktur, Orakel).	EC6 Studien, deren Fokus auf der Generierung synthetischer Testdaten (Eingabewerte, Datensätze) liegt, ohne die Erzeugung von Testfällen selbst zu adressieren.
IC7 Empirische Auswertung in einem realen oder repräsentativen Web-UI- bzw. E2E-Setting (mind. ein Browser, eine Webanwendung oder ein Web-Frontend).	EC7 Studien, deren Untersuchungsobjekt rein synthetisch ist (z. B. nur HTML-Snippets ohne Anwendungslogik) oder die Web-Bezug nur am Rand erwähnen.

7 Qualitätsbewertung der Studien

Eingeschlossene Studien werden zusätzlich einer formalen Qualitätsbewertung unterzogen. Sie dient nicht als weiteres Ausschlusskriterium, sondern als Gewichtungshilfe in der Synthese und als Grundlage für eine Sensitivitätsanalyse. Verwendet wird ein an Kitchenham und Charters angelehntes Schema mit sechs gleich gewichteten Kriterien, die auf einer dreistufigen Skala (0 = nicht erfüllt, 0,5 = teilweise erfüllt, 1 = vollständig erfüllt) bewertet werden. Der Gesamtwert liegt zwischen 0 und 6; Werte ab 3 gelten als methodisch hinreichend, ab 4,5 als methodisch hochwertig.

Nr.	Qualitätskriterium	Skala
Q1	Sind Zielsetzung und Forschungsfragen klar formuliert?	0 / 0,5 / 1
Q2	Wird der Ansatz ausreichend zur Reproduktion beschrieben?	0 / 0,5 / 1
Q3	Ist das Studiendesign (Datensätze, Baselines) angemessen?	0 / 0,5 / 1

Nr.	Qualitätskriterium	Skala
Q4	Werden die verwendeten Metriken klar definiert und begründet?	0 / 0,5 / 1
Q5	Werden Threats to Validity diskutiert?	0 / 0,5 / 1
Q6	Sind die Ergebnisse nachvollziehbar und ausreichend belegt?	0 / 0,5 / 1

8 Datenextraktion

Für jede eingeschlossene Studie wird ein einheitliches Extraktionsformular ausgefüllt, das unmittelbar aus den Forschungsfragen abgeleitet ist. Erfasst werden bibliografische Angaben, der Studienkontext (Domäne, Sprachen, Frameworks, Größe der Fallstudien), der eingesetzte Ansatz (Klassifikation als LLM-basiert, traditionell oder hybrid; Modelle und Werkzeuge; algorithmische Grundlage), das Evaluationsdesign (Baselines, Datensätze, Benchmarks, Wiederholungen, statistisches Vorgehen), die verwendeten Qualitätsmetriken (Coverage, Mutation Score bzw. Fehlererkennung, funktionale Korrektheit, Executability, Flakiness, Verständlichkeit), die quantitativen und qualitativen Ergebnisse sowie die von den Autorinnen und Autoren benannten Limitationen. RQ1 wird dabei primär über Ansatz und Kontext beantwortet, RQ2 über Metriken und Evaluationsdesign, RQ3 über die integrierte Betrachtung von Ansatz, Evaluationsdesign und Ergebnissen. Die extrahierten Daten werden strukturiert in tabellarischer Form (Excel/CSV) geführt, um deskriptive Auswertungen und eine spätere Replikation zu erleichtern.

9 Datenanalyse und Synthese

Die Auswertung verbindet deskriptive und vergleichend-narrative Elemente entlang der Forschungsfragen. In einem ersten Schritt wird die Studienlandschaft quantitativ beschrieben (zeitliche Verteilung, Publikationsart, Web-Domäne, eingesetzte Modelle, Werkzeuge und Basisalgorithmen); damit wird RQ1 adressiert. Anschließend werden die in den Primärstudien berichteten Metriken konsolidiert und über eine Mapping-Tabelle den Teilmerkmalen der Functional Suitability nach ISO/IEC 25010 zugeordnet: funktionale Korrektheit und Mutation Score bevorzugt Functional Correctness, Code Coverage und Executability primär Functional Completeness, Anforderungs- bzw. Szenarioangemessenheit dem Bereich Functional Appropriateness; dies beantwortet RQ2, ohne den Primärstudien den Einsatz des Standards zu unterstellen.

Im dritten Schritt erfolgt die vergleichende Analyse zwischen LLM-basierten, traditionellen und hybriden Ansätzen entlang der gemappten Qualitätsdimensionen. Ergebnisse werden, soweit die Evaluationskontexte vergleichbar sind, in Übersichtstabellen gegenübergestellt; andernfalls werden sie narrativ synthetisiert und Unterschiede im Studiendesign offen diskutiert. Die narrative Synthese verdichtet die Evidenz pro Dimension, benennt Widersprüche explizit und gewichtet Befunde nach der Qualitätsbewertung aus Abschnitt 7. Abschließend werden die Ergebnisse in Kernaussagen pro Forschungsfrage zusammengeführt und bilden die Grundlage für Diskussion, Handlungsempfehlungen und die Ableitung weiterführenden Forschungsbedarfs.